Detección automática de series estadísticas mediante comprensión de lenguaje natural: aplicación al Banco Central de Chile

Sebastián Mena Aliaga
División de Estadísticas y Datos
Banco Central de Chile
smena@bcentral.cl

Hernán Fernández Carné
División de Estadísticas y Datos
Banco Central de Chile
hfernandez@bcentral.cl

Abstract

El acceso a estadísticas económicas publicadas por bancos centrales requiere típicamente que el usuario conozca el catálogo de datos disponible, lo que representa una barrera para economistas y público general. En este trabajo se propone un sistema de comprensión de consultas en lenguaje natural que detecta de forma conjunta entidades e intenciones para identificar automáticamente la o las series estadísticas solicitadas y el modo en que deben ser entregados sus valores, aplicado a las series de la Base de Datos Estadísticos del Banco Central de Chile. Las entidades y clasificaciones detectadas son normalizadas y mapeadas mediante un catálogo estructurado hacia las series correspondientes.

1. Introducción

Los bancos centrales y organismos estadísticos publican vastos catálogos de series de datos económicos que constituyen insumos fundamentales para el análisis macroeconómico, la toma de decisiones de política pública y el seguimiento de la actividad económica. Sin embargo, el acceso a estas series exige que el usuario conozca con precisión la estructura interna del catálogo: qué indicadores existen, cómo se denominan, qué desagregaciones están disponibles y bajo qué criterios se organizan. Esta barrera limita el aprovechamiento de información que, en principio, es pública y de alto valor.

El procesamiento de lenguaje natural (PLN) ofrece una vía para reducir esta fricción, permitiendo que los usuarios expresen sus consultas de forma libre y que un sistema sea capaz de interpretarlas y traducirlas al lenguaje del catálogo institucional. No obstante, este problema va más allá de una simple búsqueda por palabras clave: una consulta como *"¿cuánto creció el comercio en la Región de Valparaíso el último trimestre?"* contiene múltiples dimensiones de información —el indicador, la actividad económica, la región, el período y el tipo de cálculo requerido— que deben ser identificadas y normalizadas de forma conjunta para recuperar correctamente la serie solicitada.

2. Revisión del estado del arte

Investigadores del Banco Central Europeo (ECB) desarrollaron una interfaz de chatbot utilizando técnicas de LLM y RAG. El procesamiento se basa en varios pasos secuenciales. El primero, un procesamiento de la consulta que consiste en estandarizarla usando un modelo LLM con un *system prompt* preparado para ello, con la finalidad de optimizarla para el *data retrieval*. Luego, se realiza una partición de la consulta en diferentes partes de la información. El siguiente paso consiste en el *data retrieval* para obtener las series relevantes, usando *embeddings* para almacenar las series y recuperarlas mediante FAISS. Los investigadores solo incluyeron las 1.000 series más demandadas. Las series obtenidas son evaluadas por un agente que juzga la relevancia y calidad de la respuesta

1st AI Agent Journal (2026).

generada en contraste con la pregunta original; si es satisfactorio el sistema procede a construir la respuesta específica, en caso contrario, se realiza una segunda búsqueda que representa un subconjunto de aproximadamente 300.000 series. Si sigue insatisfactorio se concluye que no se puede responder a la pregunta. Posteriormente, se obtiene la metadata de las series obtenidas y pasa por el agente de generación de SQL para obtener los datos relevantes. Finalmente, un agente redacta la respuesta al usuario.[1]

3. La taxonomía de la BDE

El presente trabajo se circunscribe a las estadísticas de cuentas nacionales del Banco Central de Chile, específicamente al Producto Interno Bruto (PIB) y al Indicador Mensual de Actividad Económica (Imacec), difundidas a través de la Base de Datos Estadísticos (BDE). La BDE se organiza en dos niveles jerárquicos. El cuadro constituye la unidad de publicación: un conjunto de series temporales que comparten indicador, compilación de referencia o base metodológica, tratamiento estacional y forma de presentación —nivel, contribución o participación—; en el caso del PIB comparten además la valoración, a precios corrientes o en volumen a precios del año anterior encadenado, distinción que no aplica al Imacec por tratarse de un índice. La serie constituye la unidad de dato: una sucesión temporal de observaciones identificada por un código único, correspondiente a una fila del cuadro. Cada cuadro presenta el indicador desagregado según una clasificación determinada, de modo que cada una de sus series corresponde a una categoría de esa clasificación: en el Imacec dicha clasificación suele ser la actividad económica, mientras que el PIB se desagrega por actividad, región, gasto o ingreso. Cabe destacar que las combinaciones de dimensiones efectivamente publicadas constituyen un subconjunto disperso de las posibles: en el Imacec, por ejemplo, la contribución año/año se publica sobre series originales y la contribución mes/mes sobre series desestacionalizadas, sin que existan las combinaciones restantes.

El universo considerado comprende 280 cuadros y 4.497 series, de las cuales 1.503 corresponden a publicaciones vigentes y el resto a compilaciones de referencia y bases metodológicas ya superadas. Se excluyeron los cuadros de deflactor del PIB, agregados macroeconómicos, formación bruta de capital fijo, PIB e ingreso, y versiones sucesivas de publicación. El Cuadro 1 presenta la composición del universo dentro del capítulo de Cuentas Nacionales.

Cuadro 1: Delimitación del universo según vigencia de publicación

	Cuadros			Series		
Familia	Vig.	Hist.	Total	Vig.	Hist.	Total
Incluidos						
PIB regional por actividad económica	65	99	164	884	1.326	2.210
Gasto del PIB	10	35	45	238	664	902
PIB por actividad económica	9	27	36	264	756	1.020
Imacec	4	13	17	38	59	97
PIB por región	5	9	14	76	160	236
PIB agregado	1	3	4	3	10	13
Subtotal	**94**	**186**	**280**	**1.503**	**2.975**	**4.478**
Excluidos						
Cuentas financieras por sector institucional	50	80	130	1.417	2.215	3.632
Gasto regionalizado	104	0	104	651	0	651
Stock de capital e inversión	19	15	34	250	445	695
Operaciones no financieras por sector	11	23	34	89	219	308
Producto e ingreso nacional	5	25	30	39	191	230
Deflactores	6	20	26	160	511	671
Ratios sectoriales	5	10	15	31	53	84
Bases de datos de revisiones	11	0	11	858	0	858
Imacec sectorial	2	4	6	56	120	176
Subtotal	**213**	**177**	**390**	**3.551**	**3.754**	**7.305**
Total capítulo Cuentas Nacionales	307	363	670	5.054	6.729	11.783

[1] `https://www.bis.org/ifc/publ/ifcb67_36.pdf`

3.1. Delimitación del ámbito de la consulta

El primer objetivo es identificar si una pregunta pertenece al ámbito económico, si se relaciona con los indicadores del PIB o el IMACEC publicados por el Banco Central de Chile, y si la pregunta puede contestarse únicamente a partir de la información oficial publicada sin necesidad de realizar análisis o interpretación de esta, con la finalidad de resguardar la reputación del Banco y responder solo aquellas preguntas que le corresponde contestar.

La literatura aborda este problema como detección de consultas fuera de dominio (*out-of-scope*) y como *answerability*, y modela el rechazo como incapacidad: el sistema no puede responder porque el dato no está, el esquema no lo soporta o la intención no fue entrenada. En el caso aquí considerado, en cambio, el rechazo obedece a un mandato institucional y no a una limitación de capacidad.

Las tres condiciones se desagregan en: ¿es del ámbito económico?, ¿se relaciona con el PIB o el IMACEC?, y ¿se responde directamente a partir de lo publicado, sin análisis? En consecuencia, se propone un clasificador de tres cabezas binarias que etiqueten la pregunta según cada una de estas condiciones.

4. Arquitectura del PIBERT

El Banco publica periódicamente las series del PIB y el Imacec organizadas por cuadros. El segundo objetivo del sistema es identificar cuáles de estas series y cuadros se mencionan, directa o indirectamente, en la pregunta. Un cuadro agrupa un conjunto de series; una misma serie puede figurar en más de un cuadro cuando el catálogo ofrece cortes alternativos del mismo dato, de modo que la resolución devuelve un conjunto de pares cuadro–serie antes que una serie aislada.

La tarea de identificar correctamente los cuadros y series que subyacen a una pregunta implica la capacidad de interpretarla a partir de un conocimiento acabado del dominio. Se propone un proceso sistematizado de interpretación e identificación utilizando herramientas de Procesamiento de Lenguaje Natural, basado en la clasificación de etiquetas y el Reconocimiento de Entidades Nombradas (NER) mediante un modelo de tipo JointBERT. La selección de las cabezas clasificadoras y los tipos de entidad que participan en la identificación conllevó la iteración, basada en prueba y error, de diferentes arquitecturas capaces de generalizar y abarcar la mayor cantidad de casos posibles. La arquitectura final se compone de ocho dimensiones enunciables en la consulta, tres cabezas clasificadoras binarias, un catálogo estructurado de resolución y un conjunto de valores por defecto.

4.1. Tipos de entidad y normalización

Cada serie del catálogo queda descrita por una tupla de catorce dimensiones, derivada de su identificador oficial. Sólo ocho de ellas admiten mención en una consulta; son las que el extractor debe resolver, mediante reconocimiento de entidades y normalización del span contra un vocabulario controlado. Cada tipo de entidad tiene asociado un conjunto de valores canónicos, y la normalización es la función que mapea las múltiples formas con que una mención puede aparecer en el texto a un único valor de ese conjunto. Dos dimensiones adicionales no identifican la serie sino la solicitud sobre ella:

```
Dimensiones de identidad (enunciables en la consulta)
INDICADOR       imacec, pib
FRECUENCIA      mensual, trimestral, anual
ESTACIONALIDAD  original, desestacionalizada
PRESENTACION    nivel, contribucion_aa, contribucion_pa, participacion
                [la ausencia de mencion se resuelve a nivel]
VALORACION      corrientes, encadenado, constantes
ACTIVIDAD       mineria, industria_manufacturera, comercio, ...   (45)
REGION          metropolitana, valparaiso, los_lagos, ...          (16)
GASTO           demanda_interna, consumo_total, fbcf, ...          (35)

Dimensiones de la solicitud (no identifican la serie)
PERIODO         fechas y expresiones temporales relativas
CALCULO         nivel, var_periodo_anterior, var_anual
```

Las seis dimensiones restantes de la tupla no dan lugar a mención en el uso corriente y se resuelven fuera del modelo: la compilación de referencia (2018, 2013, 2008, ...) sólo se enuncia excepcionalmente y toma por defecto la vigente; la vigencia de publicación, el empalme y la condición de información histórica se fijan por valores por defecto (Sección 4.4); y la apertura del cuadro y la región fija se derivan del propio catálogo. Los valores marginales del catálogo —tasas, series de tendencia-ciclo y la fila extrarregional— se conservan en la tabla de resolución pero se excluyen del vocabulario del modelo.

Los vocabularios de ACTIVIDAD, REGION y GASTO no se exponen al modelo como clases: el extractor etiqueta un span genérico del tipo correspondiente y la normalización lo resuelve contra las categorías de los cuadros candidatos, de modo que la granularidad reside en el catálogo y no en el clasificador. PERIODO y CALCULO especifican el recorte temporal y la operación solicitada, y operan como fuente indirecta de desambiguación sobre las dimensiones no enunciadas.

A modo de ilustración, en la consulta «cuánto creció el producto interno bruto sin estacionalidad» se reconocen tres menciones —«creció», «producto interno bruto» y «sin estacionalidad»— correspondientes a los tipos CALCULO, INDICADOR y ESTACIONALIDAD, que la normalización resuelve respectivamente a los valores canónicos `var_anual`, `pib` y `desestacionalizada`. La función es de muchos a uno y no reversible: las formas «sin estacionalidad», «desestacionalizado» y «serie ajustada» convergen en un mismo valor canónico, pérdida de información deliberada que otorga al sistema invarianza frente al registro en que se formula la consulta.

Tres de los vocabularios son condicionales. El de ACTIVIDAD depende del cuadro, dado que el Imacec emplea una clasificación agregada por actividad económica mientras que los cuadros de PIB emplean desagregaciones considerablemente más finas. El de PRECIO depende de la compilación de referencia, puesto que la valoración real se expresa en volumen encadenado desde la referencia 2008 y en precios constantes de año base en las compilaciones anteriores. El de REGION también depende de la referencia, en tanto la división político-administrativa vigente varía entre compilaciones.

4.2. Cabezas clasificadoras

Las cabezas clasificadoras cumplen una función complementaria a la del reconocimiento de entidades: los spans capturan las menciones que refieren a una categoría y admiten normalización contra un vocabulario controlado, mientras que las cabezas resuelven las dimensiones que no dan lugar a una mención normalizable.

Esta complementariedad se manifiesta con particular claridad en el eje de desagregación. Los cuadros del Imacec y del PIB, seleccionados, se aperturan por actividad económica, región, actividad-región, o componentes del gasto, de modo que el span normalizado sobre dicho eje —ACTIVIDAD, REGIÓN o GASTO— constituye la pieza final de la resolución, una vez determinadas las restantes dimensiones. Cabe precisar que el nivel en que opera esa pieza depende del cuadro: en los cuadros desagregados por actividad, la mención selecciona una serie especifica; en la desagregación regional, en cambio, cada región puede ser una serie o constituir un cuadro independiente desagregado por actividad económica. Cuando la consulta no nombra categoría alguna pero la cabeza del eje se activa, como en «cuánto crecieron las actividades del Imacec el mes pasado», la resolución no apunta a una serie sino al cuadro en su totalidad.

Las cabezas se denotan `activ_cls`, `reg_cls` y `gast_cls`, con valores en $\{0, 1\}$, e indican si la consulta invoca la clasificación correspondiente en su conjunto. Las tres admiten activación simultánea, lo que permite representar los cuadros de doble desagregación por región y actividad, que constituyen la mayoría del catálogo considerado.

El eje de desagregación queda determinado por la unión de ambas señales —la presencia de un span de ese tipo o la activación de la cabeza correspondiente—, mientras que su combinación fija la cardinalidad de la respuesta, según muestra el Cuadro 2.

4.3. Catálogo de resolución

Sea $\mathcal{C}$ el catálogo, donde cada cuadro $c \in \mathcal{C}$ se representa como una tupla completamente especificada $c = (c_1, \ldots, c_k)$ sobre los vocabularios $V_1, \ldots, V_k$ de las dimensiones descritas en la Sección 4.1. La tabla se deriva de la metadata de publicación sin construcción manual: el identificador de cada serie está compuesto por segmentos que codifican las dimensiones del cuadro al que pertenece, de

Cuadro 2: Cardinalidad de la respuesta según las señales sobre el eje de desagregación

Span	Cabeza	Resolución
–	0	fila agregada del cuadro
sí	0	las categorías mencionadas
–	1	el cuadro en su totalidad
sí	1	el cuadro en su totalidad, con las categorías mencionadas destacadas

modo que $\mathcal{C}$ se obtiene decodificando los identificadores del catálogo oficial. Esta propiedad hace el procedimiento transferible a cualquier oficina estadística que difunda sus series mediante claves estructuradas.

La consulta, en cambio, produce una tupla *parcial* $q \in \prod_i (V_i \cup \{\perp\})$, donde $\perp$ denota una dimensión que el extractor no resolvió. Las posiciones no especificadas no restringen, de manera que el conjunto candidato queda definido por

$$\mathcal{C}(q) \;=\; \{\, c \in \mathcal{C} \;:\; \forall i,\; q_i = \perp \;\vee\; q_i = c_i \,\}.$$

La resolución concluye cuando $|\mathcal{C}(q)| = 1$. Si $|\mathcal{C}(q)| > 1$, la dimensión de mayor cardinalidad en el conjunto residual señala el eje sobre el cual formular una pregunta aclaratoria. Si $\mathcal{C}(q) = \emptyset$, la combinación solicitada no existe en el catálogo, lo que constituye evidencia de un error de extracción o de una consulta ajena al universo publicado.

La eficacia de este filtrado descansa en la dispersión del catálogo, que es extrema: las once dimensiones de cuadro admiten $5{,}16 \times 10^6$ combinaciones, de las cuales el catálogo publica 275 tuplas distintas para 276 cuadros. Cabe observar que la proyección no es completamente inyectiva: un par de cuadros comparte tupla —el PIB trimestral y el PIB anual por región de la referencia 2018— por una inconsistencia de frecuencia en la metadata de origen, que codifica ambos como trimestrales.

4.4. Resolución de dimensiones no enunciadas

Sobre el conjunto candidato operan dos mecanismos de naturaleza distinta.

El primero es la *propagación de restricciones*, que colapsa aquellas posiciones $\perp$ que toman un valor único a lo largo de $\mathcal{C}(q)$: la dimensión queda determinada por la estructura del catálogo, sin que la consulta la enuncie ni el modelo la infiera. Así, en «cuánto creció la economía el último trimestre», el reconocimiento de la frecuencia trimestral excluye al Imacec —que solo se publica con periodicidad mensual— y fuerza la resolución hacia el Producto Interno Bruto; de manera análoga, en «cuánto aceleró la economía», la mención del cálculo respecto del período inmediatamente anterior determina que la serie solicitada sea la desestacionalizada, dado que la variación intraperiodo únicamente se publica sobre series ajustadas por estacionalidad. Estas inferencias no requieren reglas explícitas ni entrenamiento adicional: emergen del filtrado contra el conjunto de combinaciones efectivamente publicadas, cuya dispersión codifica las convenciones metodológicas del compilador.

El segundo mecanismo es la asignación de *valores por defecto* sobre las posiciones que permanecen indeterminadas tras dicho colapso. Los defaults son de tres clases, según cómo se imponen sobre el conjunto candidato (Cuadro 3).

Las *constantes* actúan como filtro previo a toda inferencia lingüística: el sistema trabaja sobre las publicaciones vigentes de la compilación de referencia actual, y sólo abre el universo histórico cuando la consulta nombra una compilación distinta. Este filtro reduce el espacio de resolución de 276 a 91 cuadros.[2]

Las *preferencias* son defaults blandos: se imponen únicamente cuando el conjunto candidato contiene el valor preferido y no restringen en caso contrario, de modo que nunca lo vacían. Su naturaleza responde a que la convención no es uniforme en el catálogo. El empalme es el caso más claro: de los 91 cuadros vigentes sólo 20 publican series empalmadas, y las contribuciones y participaciones

[2]Cifras de la exportación de la BDE de agosto de 2026; en la publicación vigente todos los cuadros corresponden a la referencia 2018 y ninguno a información histórica, de modo que la vigencia basta por sí sola para la reducción.

no lo hacen, por lo que imponerlo como constante anularía la mayoría de las resoluciones; como preferencia, en cambio, actúa sólo como desempate entre cuadros por lo demás equivalentes. Lo mismo ocurre con la valoración, donde un mismo cuadro puede ofrecer la serie a precios corrientes y en volumen encadenado, y la lectura convencional es la segunda. Las preferencias se aplican en un orden fijo y cada una que se impone queda registrada como supuesto, que se explicita en la respuesta entregada al usuario.

La *tabla condicionada*, por último, recoge convenciones de lectura cuyo valor depende de otras dimensiones de la consulta: el tratamiento estacional se resuelve según el indicador y el cálculo solicitado. A diferencia de las anteriores, no está determinada por la estructura del catálogo: debe ser mantenida institucionalmente, versionada y auditable. Cuando ambas alternativas se encuentran publicadas y ninguna convención las discrimina, la tabla no resuelve y la consulta se deriva a una pregunta aclaratoria sobre esa dimensión.

Cuadro 3: Valores por defecto sobre las dimensiones no enunciadas

Dimensión	Valor por defecto	Clase
Vigencia	vigente	constante
Información histórica	no	constante
Referencia	compilación 2018	constante, salvo mención
Presentación	nivel	preferencia
Valoración	volumen encadenado	preferencia
Empalme	serie empalmada	preferencia (desempate)
Estacionalidad	según indicador y cálculo	tabla condicionada

La aplicación conjunta de estos mecanismos permite resolver consultas que no enuncian dimensión alguna. La ausencia total de menciones, como en «cuánto creció la economía», se resuelve hacia el Imacec en su serie original de frecuencia mensual, compilación de referencia vigente y variación respecto de igual período del año anterior, por tratarse de la lectura convencional de la pregunta en el uso institucional.

4.5. Catálogo de reglas de identificación

Se define un catálogo que describe los cuadros y series como una tupla de los valores posibles de las cabezas clasificadoras y las entidades normalizadas, desde los casos más explícitos y evidentes hasta los casos implícitos que requieren un conocimiento más especializado de interpretación.

```
# Identificación del indicador
CONJ_IMACEC: (INDIC=[] y FREQ=([] o ["m"])) o
             (INDIC=["imacec"] y FREQ=(["m"] o ["t"] o ["a"]))
CONJ_PIB:    (INDIC=([] o ["pib"]) y FREQ=(["t"] o ["a"]))

# Identificación de la estacionalidad
CONJ_EST:  (EST=[] y CALC=([] o ["pct"])) o
           (EST=["est"] y CALC=([] o ["pct"] o ["ypct"]))
CONJ_DEST: (EST=[] y CALC=([] o ["pct"])) o
           (EST=["dest"] y CALC=([] o ["pct"] o ["ypct"]))
```

El tipo de cálculo informa directamente sobre el tipo de estacionalidad solicitada. Un cuadro se identifica con la combinación de las entidades y clasificadores INDIC, FREQ, DESC, EST, PREC, activ_cls, reg_cls, gast_cls e hist_cls. A continuación se presentan cuatro ejemplos de reglas:

```
Imacec, volumen a precios del año anterior encadenado,
series empalmadas (promedio 2018=100)
  NER:     CONJ_IMACEC y CONJ_EST y DESC=[] y PREC=([] o ["enc"])
  Clasif.: activ_cls=1 ; reg_cls=0 ; gast_cls=0

Imacec, contribución porcentual respecto de igual periodo
del año anterior, referencia 2018
```

```
  NER:     CONJ_IMACEC y DESC=["contr"] y ESTAC=([] o ["est"])
           y PREC=([] o ["enc"])
  Clasif.: activ_cls=1 ; reg_cls=0 ; gast_cls=0

Producto interno bruto, referencia 2018
  NER:     CONJ_PIB y DESC=[] y ESTAC=([] o ["est"] o ["dest"])
           y PREC=([] o ["enc"] o ["corr"])
  Clasif.: activ_cls=0 ; reg_cls=0 ; gast_cls=0

Participación por clase de actividad económica,
series empalmadas, referencia 2018
  NER:     CONJ_PIB y DESC=["part"] y ESTAC=([] o ["est"])
           y PREC=([] o ["enc"] o ["corr"])
  Clasif.: activ_cls=0 ; reg_cls=0 ; gast_cls=0
```

Acknowledgments and Disclosure of Funding

Use unnumbered first level headings for the acknowledgments. All acknowledgments go at the end of the paper before the list of references. Moreover, you are required to declare funding (financial activities supporting the submitted work) and competing interests (related financial activities outside the submitted work).

Referencias

A. Appendix / supplemental material

Optionally include supplemental material (complete proofs, additional experiments and plots) in appendix.